



逆强化学习：从专家行为中读出”为什么”

Inverse Reinforcement Learning —Theory, Practice & Frontiers

MiniMax ARIS Research Showcase

2026

Motivation: 奖励工程的痛点

●○○○○ 问题与动机

现实困境：奖励函数很难写

- ▶ 自动驾驶：撞车 -100 ，变道 -1 ，加速 $+0.1$
- ▶ 推荐系统：短期点击 vs 长期满意度？
- ▶ 机器人操控：“抓取成功”如何量化？
- ▶ 对话系统：“有帮助”怎么定义？

但行为数据大量存在


- ▶ 人类司机每天 **数百万条** 轨迹
- ▶ 老司机 30 年 = 示范黄金库
- ▶ LLM 阅读 1T+ token 文本

能否 从示范反推奖励？

动机 — 形式化 — 算法演进 ↑ — 应用 — 前沿

RL vs IRL: 把箭头反过来

●○○○○ 问题与动机



维度	RL	IRL
奖励来源	人为设计	从示范推断
可解释性	弱	强
数据需求	在线交互	离线可用
泛化能力	受限于塑形	可跨环境

IRL 独特价值

从数据推断 + 强可解释 + 跨环境迁移

数学形式化: MDP 与 IRL 问题定义

●●○○○ 形式化

MDP 五元组

$$\langle \mathcal{S}, \mathcal{A}, P, r, \gamma \rangle$$

- ▶ $\mathcal{S}$: 状态空间
- ▶ $\mathcal{A}$: 动作空间
- ▶ $P(s'|s, a)$: 状态转移
- ▶ $r(s, a)$: 奖励函数
- ▶ $\gamma \in [0, 1)$: 折扣因子

RL 目标

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\tau \sim \pi} \left[\sum_t \gamma^t r(s_t, a_t) \right]$$

IRL 问题

已知 $\mathcal{S}, \mathcal{A}, P, \gamma$ 和 τ_E ,
反求奖励函数 $r(s, a)$

关键性质: 奖励歧义性

$r' = r + c$ 不改变最优策略 π^*

- ▶ $\Rightarrow$ IRL 是 **病态反问题**
- ▶ $\Rightarrow$ 必须引入 **归纳偏置 (先验)**

关键洞察：特征期望匹配

●●○○○ 形式化

Ng & Russell (2000) 核心约束

$$\mathbb{E}_{\pi_E}[\phi(s, a)] = \mathbb{E}_{\pi^*}[\phi(s, a)]$$

其中 $\phi: \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}^k$
是人工设计的 **特征函数**。

线性参数化奖励：

$$r(s, a) = \theta^\top \phi(s, a)$$

求解 r 的思路

约束： $\mu_E = \mu_\pi(\theta)$

采用线性规划或
最大边距优化

但解不唯一，出现退化

核心问题：如何选择“好”的解？

► **最大边距** (Abbeel & Ng 2004)：选与最差策略差距最大的 $r \rightarrow$ 不稳定

算法演进：1998 → 2024


●●●○○ 算法演进



核心趋势：理论奠基 → 对抗学习 → 大模型对齐

经典 Pipeline: 内外双层循环

●●●●○ 算法演进



训练慢的根因


▶ 外层: 推断 r (梯度上升)

GAIL 的解法

▶ 判别器 — 软奖励信号

直观感受: 5×5 网格世界 IRL

●●●○○ 算法演进



专家示范 (8 步)

IRL 推断的奖励热图

观察:

- ▶ **目标格** 获得最高奖励值
- ▶ **奖励山脊** 沿最优路径延伸
- ▶ IRL 对噪声 **鲁棒**

核心结论

从示范反推奖励 = 可解释 + 可迁移 + 抗噪

MaxEnt IRL: 概率化消除歧义

●●●○○ 算法演进

核心思想 (Ziebart 2008)

$$P(\tau \mid r) \propto \exp(\sum_t r(s_t, a_t))$$

⇒ 最大似然 (拟合) + 最大熵 (消歧)

梯度方向 (简洁!)

$$\nabla_r = \mu_E - \mu_\pi$$

把 μ_π **拉向** μ_E



三大优势

唯一解
抗噪声
概率输出

凸优化问题
充分特征下收敛
可衡量不确定性


GAIL: 用对抗跳过显式奖励

●●●○○ 算法演进

核心公式 (Ho & Ermon 2016)

$$\min_{\pi} \max_D \underbrace{\mathbb{E}_{\tau_E}[\log D(\tau)]}_{\text{真专家}} + \underbrace{\mathbb{E}_{\tau_{\pi}}[\log(1 - D(\tau))]}_{\text{假策略}}$$

- ▶ **D (判别器)** 代替显式奖励 r
- ▶ 等同于 Jensen-Shannon 散度
- ▶ 端到端可微—无需内层 RL



局限

- ▶ 训练不稳定 (GAN 通病)
- ▶ 奖励不可迁移到新环境
- ▶ 需要大量在线交互

AIRL: 可迁移的奖励


●●●○○ 算法演进

核心创新 (Fu et al. 2017)

$$D(s, a, s') = \frac{\exp(f(s, a, s'))}{\exp(f(s, a, s')) + \pi(a|s)}$$

其中 $f(s, a, s') = g(s, a) + \gamma h(s') - h(s)$

⇒ 分离 **奖励** 与 **动力学**




对抗 + 可分离 = 跨环境泛化

可迁移性

- ▶ 奖励 $g(s, a)$: **环境无关**
- ▶ 动力学 $h(s)$: 环境相关
- ▶ 迁移 = 只换 h , 保留 g

IRL 的当代化身: RLHF $\rightarrow$ DPO

●●●●○ 应用



IRL 视角看 RLHF

偏好数据 $\xrightarrow{\text{IRL}}$ 隐式奖励 $\xrightarrow{\text{RL}}$ 对齐策略

关键里程碑

- ▶ InstructGPT (Ouyang 2022)
RLHF 让 GPT-3 遵循指令
- ▶ DPO (Rafailov 2023)
直接优化偏好, 跳过 RL

- ▶ 自动驾驶：理解 **为什么变道**
- ▶ 机器人：从示范学 **操作意图**
- ▶ LLM 对齐：**当前最大应用场景**

●●●●○ 应用

长期满意度;

- ▶ 游戏 AI：学 **玩家风格**
- ▶ 推荐系统：学 **真实偏好**
- ▶ 对话系统：学 **有用性**

开放问题与研究前沿

●●●● 前沿

- ▶ 如何使用 **静态数据集** 替代在线交互
- ▶ 长 horizon 任务的分布偏移
- ▶ 与 Offline RL 的交叉融合

- ▶ 多个专家的 **交互奖励** 推断
- ▶ 博弈论 + IRL 的融合
- ▶ 多智能体价值对齐

- ▶ 推断的奖励必须 **尊重安全约束**
- ▶ 约束 IRL: r 在安全区域
- ▶ 与 RLHF 安全对齐直接相关

- ▶ 从海量视频/文本 **自动发现奖励**
- ▶ 预训练先验 + 少量示范微调
- ▶ 零样本 IRL 的可能性

AIRL: 可迁移分离;

[draw=good, fill=good!5, rounded corners=10pt, minimum width=3.5cm, minimum height=2.2cm] at (11, 0) (p3) ; at (11, 0.4) 当代影响; [font=] at (11, -0.3) RLHF + DPO
LLM 对齐的核心;

[->, line width=1.5pt, color=primary!40] (p1.east) – (p2.west); [->, line width=1.5pt, color=primary!40] (p2.east) – (p3.west);

[fill=primary!8, draw=primary, rounded corners=8pt] (0, -2.0) rectangle (11, -1.0); at (5.5, -1.5) 奖励
= 行为的” 压缩描述” IRL = 从行为反推意图;


关键参考文献

1. **Ng & Russell** (2000)
Algorithms for IRL. *ICML*.
2. **Abbeel & Ng** (2004)
Apprenticeship learning via IRL. *ICML*.
3. **Ziebart et al.** (2008)
Maximum entropy IRL. *AAAI*.
4. **Ho & Ermon** (2016)
Generative adversarial imitation learning. *NeurIPS*.
5. **Fu et al.** (2017)
Learning robust rewards with adversarial IRL. *ICLR*.
6. **Christiano et al.** (2017)
Deep RL from human preferences. *NeurIPS*.
7. **Ouyang et al.** (2022)
Training language models to follow instructions. *NeurIPS*.
8. **Rafailov et al.** (2023)
Direct preference optimization. *NeurIPS*.

推荐综述: Arora & Doshi (2021) A survey of IRL. *Artificial Intelligence*.

Thank You

Questions?



<https://github.com/example/irl>

MiniMax · ARIS Research Showcase · 2026